lab9 - 应用程序-自动缩放功能

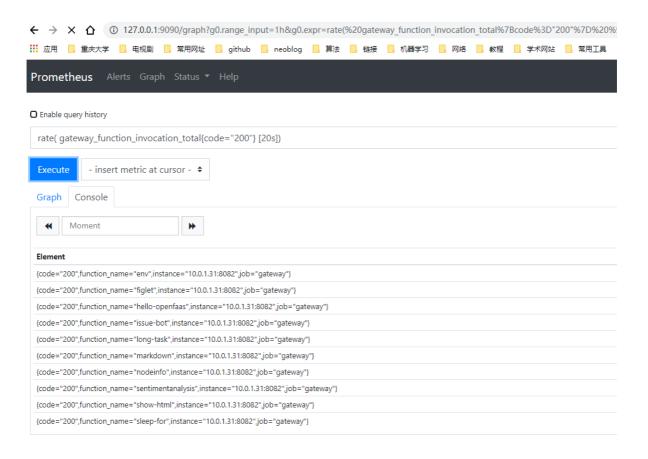
在实验9中,我学习了如何自动缩放OpenFaaS。具体来说,它具有与Prometheus的Alertmanager链接的机制。

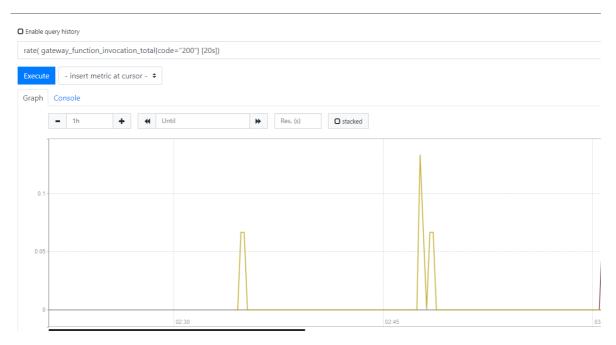
开箱即用地配置OpenFaaS,使其将根据 request per seconds 通过Prometheus测量的度量标准进行自动缩放。当流量通过API网关时会捕获此度量。如果 request per seconds 超过了定义的阈值,则 AlertManager将触发。应将此阈值重新配置为适合生产使用的级别。

其实就是自动调整负载。

打开普罗米修斯并添加一个图:

在普罗米修斯上执行这个, rate(gateway_function_invocation_total{code="200"} [20s])





http://127.0.0.1:9090/alerts 可以查看何时超过每秒请求的阈值。

Alerts

Show annotations

/etc/prometheus/alert.rules.yml > prometheus/alert.rules

service_down (0 active)

APIHighInvocationRate (0 active)

触发警告测试

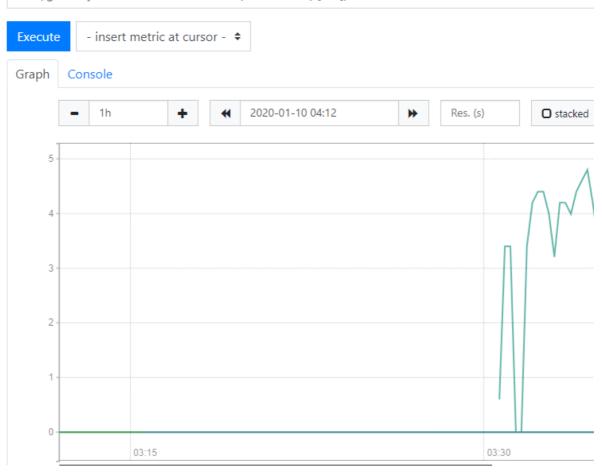
```
$ git clone https://github.com/alexellis/echo-fn \
&& cd echo-fn \
&& faas-cli template store pull golang-http \
&& faas-cli deploy \
--label com.openfaas.scale.max=10 \
--label com.openfaas.scale.min=1
```



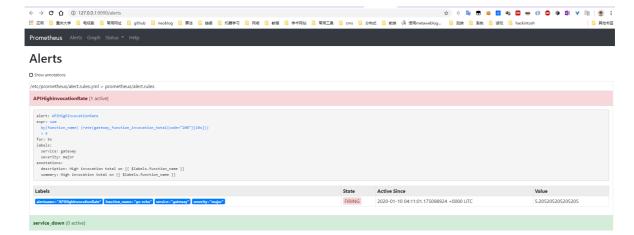
```
$ for i in {0..10000};
do
   echo -n "Post $i" | faas-cli invoke go-echo && echo;
done;
```

☑ Enable query history

rate(gateway_function_invocation_total{code="200"} [10s])



可以看到go-echo的调用次数一直增加。



一段时间后出现了高负载警告

Alerts



自动缩放后,状态更改为pending,然后警告消失。